

Science & technology | Chips away

The next phase of artificial intelligence may require very different processors

The GPUs that powered the AI boom can't handle the workload

Mar 18th 2026

컴퓨터 칩 제조업체인 엔비디아(Nvidia)는 세계에서 가장 가치 있는 기업입니다. 엔비디아는 1990년대 후반에 개척한 칩인 그래픽 처리 장치(GPU)의 다재다능함 덕분에 성공을 거두었습니다. 원래 비디오 게임의 화질을 높이기 위해 설계된 GPU는 대규모 언어 모델(LLM)을 훈련하는 데 매우 적합한 것으로 드러났습니다. 이 발견으로 엔비디아 칩에 대한 수요와 기업 가치는 급등했습니다.

시대는 빠르게 변하고 있습니다. AI 컴퓨팅 수요는 모델을 훈련하는 것에서 실제 질의에 답을 내놓게 하는 과정인 '추론(Inference)'으로 옮겨가고 있습니다. 컨설팅 업체 맥킨지(McKinsey)는 이 장치(2020년대)가 끝날 무렵에는 추론이 AI 데이터 센터 수요의 5분의 3을 차지할 것으로 추정합니다. 엔비디아도 이러한 변화를 인식하고 있는 것으로 보입니다. 지난 3월 16일, 엔비디아는 전통적인 GPU에서 벗어난 아키텍처를 갖춘, 추론 작업을 위해 특별히 설계된 새로운 칩인 Groq 3 LPX를 공개했습니다.

이번에는 경쟁자가 아주 많을 것입니다. 엔비디아보다 더 빠르고 효율적으로 AI 모델을 실행하는 것을 목표로 칩을 만드는 스타트업들이 속속 등장하고 있습니다.

훈련과 추론은 하드웨어에 서로 다른 요구 사항을 제시합니다. 방대한 양의 가공되지 않은 데이터에서 패턴을 식별하도록 AI 모델을 가르치는 '훈련'은 병렬로 수행되는 엄청난 횟수의 연산에 의존합니다. 예를 들어 엔비디아의 주력 제품 중 하나인 B200 칩은 이러한 연산을 수행하기 위해 '코어(core)'라고도 불리는 16,000개 이상의 처리 장치를 포함하고 있습니다.

반면, 학습을 마친 모델이 사용자 프롬프트에 응답하기 위해 훈련 내용을 불러오는 '추론'은 다르게 작동합니다. 추론은 '프리필(fill)'과 '디코드(decode)'의 두 단계로 전개됩니다. 프리필 단계에서 모델은 프롬프트를 처리하여 이를 '토큰(token)'이라고 불리는 작은 텍스트 단위(영어의 경우 보통 약 4글자)로 변환합니다. 속도를 높이기 위해 질의의 서로 다른 부분을 토큰화하는 작업은 병렬로 수행될 수 있습니다. 이후 디코딩 단계에서 토큰별로 응답을 생성합니다. 이를 위해 모델은 훈련 중에 학습한 토큰 간의 관계인 '가중치(weights)'와 이전에 생성된 토큰들에 의존합니다. 이 가중치들은 시스템의 메모리에 저장됩니다.

끊임없는 메모리 접근의 필요성은 현대적인 GPU가 한계를 드러내는 지점입니다. B200과 같은 AI 프로세서는 칩 내부에 작지만 극도로 빠른 메모리인 SRAM과, 훨씬 크지만

칩 외부에 있는 메모리인 DRAM을 포함하고 있습니다. DRAM에 접근하는 것은 SRAM을 읽는 것보다 10배 더 느릴 수 있으며 훨씬 더 많은 에너지를 소비합니다. 문제는 점점 악화되고 있습니다. AI 모델이 커지고 긴 프롬프트를 처리하는 능력이 좋아짐에 따라 메모리 수요가 급격히 늘고 있기 때문입니다. 캘리포니아 대학교 버클리 캠퍼스의 아미르 골라미(Amir Gholami) 교수팀의 연구에 따르면, 지난 20년간 컴퓨팅 성능은 몇 년마다 약 3배씩 향상된 반면, 외부 메모리 대역폭은 약 1.6배 향상되는 데 그쳤습니다. 이 '메모리 벽(memory wall)'은 AI 추론 속도를 높이는 데 있어 주요 병목 현상이 되었습니다.

이 점을 반드시 기억해야 합니다

GPU는 이를 극복하기 위해 소프트웨어적인 우회 방식에 의존합니다. 한 가지 접근 방식은 두 단계를 서로 다른 프로세서로 나누는 것입니다. 프리필 단계는 높은 병렬 컴퓨팅 파워에 최적화된 GPU에서 실행하고, 디코딩은 빠른 메모리 접근을 위해 설계된 별도의 GPU에서 실행하는 식입니다. 또 다른 기술은 여러 질의를 함께 처리하는 '배칭(batching)'입니다. 모델 가중치가 로드되면 여러 질의에 동시에 사용할 수 있어 외부 메모리로의 반복적인 이동을 줄여줍니다.

엔비디아의 신형 칩은 소프트웨어의 힘을 빌려 온칩(on-chip) 메모리를 강화합니다. SRAM의 크기는 약 500메가바이트로, B200의 192기가바이트 외부 메모리에 비하면 매우 작습니다. 차이를 만드는 것은 모든 데이터 조각이 칩을 통과하는 방식을 지휘하여 연산과 메모리 접근을 극대화하는 스마트 소프트웨어입니다.

스타트업들은 더 급진적인 설계를 실험하고 있습니다. 한 가지 방식은 단순히 더 큰 칩을 만드는 것입니다. 미국 칩 설계업체 세레브라스(Cerebras)가 취한 방식입니다. 저녁 식사 접시 크기인 이 회사의 최신 칩은 무려 900,000개의 코어와 44기가바이트의 온칩 SRAM을 포함하고 있습니다. 모든 데이터 이동이 웨이퍼 내부에서 일어나기 때문에, 세레브라스는 자사 시스템이 기존 설계보다 추론을 최대 15배 더 빠르게 수행할 수 있다고 주장합니다. 하지만 매우 거대한 모델의 경우 모든 매개변수를 SRAM에 저장하는 것은 비현실적입니다.

다른 이들은 코어를 통해 데이터가 이동하는 방식을 재설계함으로써 이 문제를 해결하려 합니다. 전직 구글 칩 엔지니어들이 설립한 스타트업 매트엑스(MatX)는 구글의 텐서 처리 장치(TPU)에 사용된 아이디어를 발전시키고 있습니다. 이 칩들은 '시스톨릭 어레이(systolic array)'라고 불리는 방식에 의존하는데, 이는 마치 몸속에서 피가 펌프질 되는 것처럼 데이터가 리듬감 있게 흐르는 처리 요소들의 격자망입니다. 각 계산 후 결과는 즉시 다음 장치로 전달되어 중간 결과를 메모리에 저장할 필요를 없앱니다. 그러나 전통적인 시스톨릭 어레이는 크기가 고정되어 있습니다. 큰 작업을 위해 크게 만들면 종종

유티 상태로 남게 되고, 작게 만들면 큰 작업이 들어왔을 때 효율이 떨어집니다. 팻엑스는 프로세서를 여러 개의 작은 격자로 나누어, 칩이 프리필을 처리하느냐 디코딩을 처리하느냐에 따라 컴퓨팅 자원을 다르게 할당하는 '분할 가능한(splittable)' 시스톨릭 어레이를 제안합니다.

캘리포니아에 본사를 둔 스타트업 디매트릭스(d-Matrix)가 추진하는 세 번째 방식은 동일한 구성 요소가 메모리와 연산을 모두 처리하게 함으로써 메모리 벽을 완전히 제거하려 합니다. '인메모리 컴퓨팅(in-memory computing)'으로 알려진 이 아키텍처는 낮은 에너지 사용량과 빠른 추론을 약속합니다.

또 다른 이들은 효율성을 더욱 높이기 위해 특정 알고리즘에 맞춰 구축된 칩 설계를 옹호합니다. 캘리포니아의 또 다른 스타트업 에치드(Etched)는 대부분의 LLM의 기반이 되는 알고리즘인 트랜스포머(Transformer) 모델을 실행하기 위해 맞춤 제작된 칩을 설계하고 있습니다. 이러한 특수화를 통해 회사는 다른 용도에 필요한 하드웨어를 제거하고 칩에서 실행되는 소프트웨어를 단순화할 수 있습니다. 중국의 연구자들은 훨씬 더 급진적인 형태의 특수화를 제안했습니다. 모델 가중치를 하드웨어에 직접 내장하는 방식입니다. 중국과학원의 한 설계에서는 가중치들이 금속 배선의 배치에 물리적으로 인코딩되어 있습니다. 저자들은 이 기술이 메모리에서 매개변수를 가져올 필요를 없애 극도로 높은 효율을 가능케 한다고 주장합니다.

하지만 이러한 특수화에는 리스크가 따릅니다. 새 칩을 설계하는 데는 보통 12~18개월이 걸리는 반면, AI 알고리즘은 그보다 훨씬 빠르게 진화합니다. 오늘날 지배적인 모델 아키텍처를 중심으로 구축된 칩은 분야의 흐름이 바뀌면 금세 구식이 될 수 있습니다.

승부의 결과는 아직 나오지 않았습니다. 엔비디아의 라이벌들은 각기 다른 단계에 있습니다. 세레브라스는 이미 3세대 칩을 내놓았고, 디매트릭스는 올해 첫 범용 버전을 출시할 예정입니다. 팻엑스와 에치드를 포함한 다른 기업들은 아직 개발 단계에 있습니다. 엔비디아는 Groq 3 LPX가 올해 하반기에 시장에 출시될 것이라고 밝혔습니다. GPU가 훈련 시장을 정복했다는 것은 분명해 보입니다. 하지만 다음에 무엇이 올지 추론(Infering)하는 것은 더 어려운 일입니다.

<https://www.economist.com/science-and-technology/2026/03/18/the-next-phase-of-artificial-intelligence-may-require-very-different-processors>